

Classification

Fouille de données (Data Mining)

Chapitre 4

Polytech Marseille

Département Informatique

4^e année

Plan du chapitre

- ◆ Introduction
- ◆ k plus proches voisins
- ◆ Arbres de décision
- ◆ Classifieurs bayésiens naïfs
- ◆ Choix et évaluation de modèles
- ◆ Méthodes d'agrégation de modèles
- ◆ Annexe : biais dans les données ; autres algorithmes


Introduction

- ♦ Classification (supervisée)
- ♦ **Variable cible** (catégorielle) présente dans les données
- ♦ Chaque exemple (observation) est accompagné d'un "label" (étiquette) indiquant à quelle **classe** il appartient (churner, spam, chat, ...)

- ♦ Construction d'un modèle en l'entraînant sur des données d'apprentissage

- ♦ **Évaluation** du modèle généré sur des données de **test**

- ♦ **Classement**/Prédiction de nouveaux exemples par le modèle₃




K plus proches voisins

Généralités

- ◆ "Lazy learning" : apprentissage paresseux
- ◆ Pas de réelle phase d'apprentissage
- ◆ Ensemble des données d'apprentissage : modèle
- ◆ K = **nombre de voisins** à considérer

pour décider de la classe d'un nouvel exemple

- ◆ **Distance**
- ◆ **Vote à la majorité**




K plus proches voisins

Choix de K

- ◆ Choix de la valeur de K
- ◆ Si **K trop petit** : sensibilité au bruit

(exemples non représentatifs)

- ◆ Si **K trop grand** : voisinage peut inclure des exemples d'autres classes donnant un résultat incorrect



K plus proches voisins

Bilan

- ◆ Souvent performant (si suffisamment d'exemples)
- ◆ Apprentissage ultra simple : apprentissage par cœur (mémorisation des exemples d'apprentissage)
- ◆ **Temps de prédiction peut être long** : calcul distances avec tous les exemples pour trouver les K plus proches
- ◆ Ne pas prendre un **K** trop élevé
- ◆ Variante : à la place de la moyenne sur les K voisins les plus proches, prendre tous les exemples, mais en les pondérant selon leur distance (une telle pondération s'appelle un noyau)

Arbres de décision


Généralités

- ◆ Arbre de décision :
 - ◆ Chaque nœud interne est étiqueté par une **variable**
 - ◆ Chaque arête est étiquetée par un **prédicat** pouvant s'appliquer à la variable du nœud parent
 - ◆ Chaque feuille est étiquetée par une **classe**
- ◆ Pour classer un nouvel exemple :
 - ◆ Suivre le **chemin** partant de la racine à une feuille de l'arbre en effectuant les différents tests à chaque nœud
- ◆ Classe allouée à une feuille :
 - ◆ Classe majoritairement représentée parmi les exemples qui correspondent à cette feuille

Arbres de décision

Exemple

- ◆ Exemple : arbre de décision permettant de savoir si un client est susceptible d'acheter ou non un nouveau produit



Arbres de décision

Quelques algorithmes

- ♦ **ID3** (Iterative Dichotomiser 3)
- ♦ **C4.5** (extension de ID3) et **C5.0**
- ♦ **CART** (Classification and Regression Trees)
- ♦ **CHAID** (Chi-square Automatic Interaction Detection)
- ♦ **SPRINT** (Scalable Parallelizable Induction of Decision Tree)
- ♦ ...

Arbres de décision

Algorithme de base

- ♦ Construction de manière **descendante, récursive** et **diviser pour régner**
- ♦ Au départ : tous les exemples d'apprentissage sont à la racine
- ♦ Les exemples sont **partitionnés de manière récursive en fonction des variables sélectionnées**
- ♦ Sur chaque nœud, les **variables sont sélectionnées** en fonction des exemples d'apprentissage sur ce nœud et d'une **mesure heuristique ou statistique** (par exemple, le gain d'information)
- ♦ **Conditions d'arrêt** du partitionnement :
 - ♦ Tous les exemples d'un nœud donné appartiennent à la même classe
 - ♦ Il ne reste plus de variables pour un partitionnement ultérieur
 - ♦ Il n'y a plus d'exemples
- ♦ Le vote à la majorité est utilisé pour classer une feuille

Arbres de décision

Algorithme ID3

ID3(exemples, cible, attributs) :

si tous les exemples sont positifs (resp. négatifs) **alors**
 retourner une feuille avec l'étiquette positif (resp. négatif)

si attributs est vide **alors**

retourner une feuille avec l'étiquette la plus fréquente

sinon

$A \leftarrow$ attribut de plus grand gain d'information

construire un noeud avec l'étiquette A

pour chaque valeurs v_i de A

ajouter la branche v_i au noeud

si exemples($A = v_i$) est vide **alors**

ajouter à la branche la feuille
 avec l'étiquette la plus fréquente

sinon

ajouter à la branche le sous-arbre

 ID3(exemples($A = v_i$), cible, attributs $- A$)

Arbres de décision

Entropie et gain d'information

- ♦ **Entropie** pour une variable aléatoire discrète Y prenant m valeurs : $y_1, y_2, \dots, y_m$

$$H(Y) = - \sum_{i=1}^m p_i \log(p_i) \quad \text{where } p_i = P(Y = y_i)$$

- ♦ Soit p_i la probabilité qu'un exemple arbitraire de D appartienne à la classe C_i (estimée par $|C_{i,D}|/|D|$ où $|C_{i,D}|$ est le nbre d'exemples de C_i dans D)

- ♦ Information (**entropie**) nécessaire pour classer un exemple dans D :

$$Info(D) = - \sum_{i=1}^m p_i \log_2(p_i)$$

- ♦ Information nécessaire (après avoir utilisé A pour diviser D en v partitions) pour classer D :

$$Info_A(D) = \sum_{j=1}^v \frac{|D_j|}{|D|} \times Info(D_j)$$

- ♦ **Gain d'information** en utilisant la variable A :

$$Gain(A) = Info(D) - Info_A(D)$$

Arbres de décision

Variables numériques

- ◆ Si variable numérique ?
- ◆ 1^{re} méthode
discrétiser (et traiter comme variable catégorielle)
- ◆ 2^e méthode
déterminer le **meilleur point de séparation** (point entre une paire de valeurs adjacentes permettent le meilleur gain d'information)

Arbres de décision

Mesures de sélection de variable

- ♦ **Gain d'information (ID3)**
- ♦ **Gain ratio (C4.5) :**

$$\text{GainRatio}(A) = \text{Gain}(A) / \text{SplitInfo}(A)$$

$$\text{où } \text{SplitInfo}_A(D) = - \sum_{j=1}^v \frac{|D_j|}{|D|} \times \log_2 \left(\frac{|D_j|}{|D|} \right)$$

- ♦ **Indice de Gini (CART) :**

$$gini(D) = 1 - \sum_{j=1}^n p_j^2 \quad gini_A(D) = \frac{|D_1|}{|D|} gini(D_1) + \frac{|D_2|}{|D|} gini(D_2)$$

$$\Delta gini(A) = gini(D) - gini_A(D)$$

- ♦ Test d'indépendance du **Chi2** (CHAID)

Arbres de décision

Mesures de sélection de variable

- ♦ **Gain d'information :**

biaisé par les variables multivaluées (variables avec un grand nombre de valeurs)

- ♦ **Gain ratio :**

tendance à préférer les séparations non équilibrées (où une partie est beaucoup plus petite que les autres)

- ♦ **Indice de Gini :**

biaisé par les variables multivaluées et a des difficultés si les effectifs des classes est élevé, de plus, tendance à favoriser les partitions de taille égale et de pureté égale

Arbres de décision

Sur-apprentissage et élagage

- ◆ Tendance à **sur-apprendre** (apprendre par cœur les données d'apprentissage)
 - ◆ Trop de branches (trop spécifique), certaines peuvent refléter des anomalies dues au bruit ou à des valeurs aberrantes
 - ◆ Mauvaise précision pour les exemples non vus
- ◆ Deux approches pour éviter cela et garder une capacité à généraliser :
 - ◆ **Pré-élagage** : arrêter la construction de l'arbre tôt - ne pas diviser un nœud si cela entraînerait la chute de la mesure de qualité en dessous d'un seuil (difficile de choisir un seuil approprié)
 - ◆ **Post-élagage** : enlever les branches d'un arbre "entièrement développé" - obtenir une séquence d'arbres progressivement élagués.

Utiliser un ensemble de données différent des données d'apprentissage pour décider quel est "l'arbre le mieux taillé"

Arbres de décision

Bilan

- ♦ Vitesse d'apprentissage relativement **rapide**
- ♦ Attention au sur-apprentissage (**overfitting**) :
élagage pour capacité de généralisation
- ♦ **Modèle facile à comprendre**
- ♦ Convertible en **règles de classification simples**
- ♦ **Résultats faciles à expliquer**
- ♦ Performances comparables à d'autres méthodes

Classification bayésienne naïve

Généralités

- ◆ Classifieur statistique : effectue une **prédiction probabiliste** (c'est-à-dire donne les probabilités d'appartenance à une classe)
- ◆ Fondé sur le théorème de **Bayes**
- ◆ Performances comparables à celles d'un arbre de décision et d'un réseau de neurones
- ◆ Incrémental : chaque exemple d'apprentissage peut augmenter/diminuer progressivement la probabilité qu'une hypothèse soit correcte

Classification bayésienne naïve

Théorème de Bayes

♦ Théorème probabilité totale

(A_i mutuellement exclusif : $\sum p(A_i) = 1$)

$$p(B) = \sum_i p(B|A_i)p(A_i)$$

♦ Théorème de Bayes

$$p(H|\mathbf{X}) = \frac{p(\mathbf{X}|H)P(H)}{p(\mathbf{X})} \propto p(\mathbf{X}|H) P(H)$$

→ Probabilité a posteriori (ce que nous devrions choisir)

↗ Vraisemblance
(ce que nous venons de voir)

↖ Probabilité a priori
(ce que nous savons précédemment)

$\mathbf{X}$: un nouvel exemple

H : $\mathbf{X}$ appartient à la classe C

classification : maximiser la probabilité a posteriori

Classification bayésienne naïve

Hypothèse naïve

- ◆ Cas particulier : **naïf**
 - ◆ Hypothèse supplémentaire pour simplifier le modèle en obtenant des performances comparables
 - ◆ **Variables conditionnellement indépendantes** (pas de relation de dépendance entre les variables)

$$p(X|C_i) = \prod_k p(x_k|C_i) = p(x_1|C_i) \cdot p(x_2|C_i) \cdots p(x_n|C_i)$$

Classification bayésienne naïve

En bref

- ♦ **Apprentissage** : calcul des probabilités de chaque valeur de variable pour chaque classe à partir des exemples d'apprentissage.
- ♦ **Classement** d'un nouvel exemple : recherche de la classe qui maximise les probabilités conditionnelles des valeurs des variables selon la classe
- ♦ Nouvel exemple $\mathbf{X} = x_1, x_2, \dots, x_n$, deux classes $\mathbf{C}_1$ et $\mathbf{C}_2$
- ♦ Calcul de : $\mathbf{P}(\mathbf{X} | \mathbf{C}_1) = P(x_1 | \mathbf{C}_1) \times \dots \times P(x_n | \mathbf{C}_1)$
et de $\mathbf{P}(\mathbf{X} | \mathbf{C}_2) = P(x_1 | \mathbf{C}_2) \times \dots \times P(x_n | \mathbf{C}_2)$
- ♦ $\mathbf{P}(x_i | \mathbf{C}_k)$: fréquence relative des exemples possédant la valeur x_i dans la classe $\mathbf{C}_k$
- ♦ $\mathbf{P}(\mathbf{C}_k)$ est la fréquence relative des exemples de la classe $\mathbf{C}_k$
- ♦ Nouvel exemple $\mathbf{X}$ est alors classé dans la classe $\mathbf{C}_k$ qui a donné la plus grande probabilité $\mathbf{P}(\mathbf{X} | \mathbf{C}_k) \times \mathbf{P}(\mathbf{C}_k)$ (= $\mathbf{P}(\mathbf{C}_k | \mathbf{X})$)

Classification bayésienne naïve

Types de variable

- ◆ Si la variable x_k est **catégorielle** :

$$p(X|C_i) = \prod_k p(x_k|C_i) = p(x_1|C_i) \cdot p(x_2|C_i) \cdots p(x_n|C_i)$$

Avec $p(x_k = v_k | C_i)$: nbre d'exemples de C_i ayant $x_k = v_k$ divisé par $|C_{i,D}|$ (nbre d'exemples de C_i dans D)

- ◆ Si la variable x_k est **numérique (continue)** :

$p(x_k = v_k | C_i)$ est calculée en se basant sur une distribution Gaussienne

$$p(x_k = v_k | C_i) = N(x_k | \mu_{C_i}, \sigma_{C_i}) = \frac{1}{\sqrt{2\pi}\sigma_{C_i}} e^{-\frac{(x - \mu_{C_i})^2}{2\sigma^2}}$$

Classification bayésienne naïve

Bilan

- ♦ Avantages
 - ♦ **Facile** à mettre en œuvre
 - ♦ Bons résultats obtenus dans la plupart des cas
- ♦ Inconvénients
 - ♦ Nécessite une connaissance initiale de **nombreuses probabilités** qui peuvent ne pas être disponibles ou impliquer des **coûts de calcul** importants
 - ♦ Hypothèse : **indépendance des variables**, donc une perte de précision. Mais les dépendances existent entre variables (→ modélisation avec réseaux bayésiens)

Choisir un modèle

- ◆ Nombreuses méthodes de classification
 - Arbre de décision, Régression logistique, SVM, Réseaux de neurones MLP, ...
- ◆ Y a-t-il une méthode supérieure aux autres (quelque soit le problème) ?
 - Sans information *a priori* sur le problème à traiter, pas de méthode supérieure à une autre
- ◆ Laquelle choisir ?
- ◆ Comment comparer les modèles de classification ?

Évaluation de modèles

Généralités

- ◆ Méthodes d'évaluation :
 - ◆ Holdout
 - ◆ Validation croisée (Cross Validation)
 - ◆ Bootstrap (cf. annexe)
- ◆ Étude et comparaison de résultats :
 - ◆ Matrice de confusion
 - ◆ Mesures : accuracy, précision, rappel, ...
 - ◆ Courbe ROC et l'AUC

Évaluation de modèles


Holdout

- ◆ Données partitionnées aléatoirement en deux ensembles indépendants
- ◆ Ensemble d'apprentissage (**training set**) (e.g., 80%) pour la construction du modèle
- ◆ Ensemble de test (**test set**) (e.g., 20%) pour l'évaluation des performances (*accuracy...*)
- ◆ Variante : répéter "holdout" k fois, l'*accuracy* est alors la moyenne des valeurs d'*accuracy* obtenues

Évaluation de modèles

Validation croisée (1/2)

- ◆ Partitionnement des données en **k sous-ensembles disjoints** S_i
- ◆ **k-fold** : apprentissage sur k-1 parties, test sur celle restante (sur chaque possibilité) (résultat = moyenne)
- ◆ Exemple : 3-fold cross validation



- ◆ Autre : **Leave-one-out** (1 seul exemple pour tester)

Évaluation de modèles

Validation croisée (2/2)

- ♦ Validation croisée **répétée** (repeated cross-validation)
 - ♦ Répétition de validations croisées un certain nombre de fois
 - ♦ Donne une estimation de la variance de l'erreur de généralisation
- ♦ Validation croisée **stratifiée** (stratified cross-validation)
 - ♦ ***Distribution des classes*** est approximativement la même dans chaque "fold" que dans les données initiales
 - ♦ Important lorsque les **classes sont déséquilibrées** dans les données et l'ensemble de données est relativement petit

Évaluation de modèles

Mesures d'évaluation (1/2)

- ♦ **TP** : vrais positifs
- ♦ **FP** : faux positifs
- ♦ **TN** : vrais négatifs
- ♦ **FN** : faux négatifs

	Classe prédite		
Classe réelle		Oui	Non
	Oui	TP	FN
	Non	FP	TN

- ♦ **Accuracy** = $(TP + TN) / (TP + FP + TN + FN)$
Pourcentage d'exemples (de "test") correctement classés
- ♦ **Taux d'erreur** = $1 - \text{accuracy}$
- ♦ **Sensibilité** (ou **rappel**) = $TP / (TP + FN)$
Taux de reconnaissance des vrais positifs (TP)
- ♦ **Spécificité** = $TN / (TN + FP)$
Taux de reconnaissance des vrais négatifs (TN)
- ♦ **Taux de faux positifs** = $1 - \text{spécificité}$
- ♦ **Taux de faux négatifs** = $1 - \text{sensibilité}$

Évaluation de modèles

Mesures d'évaluation (2/2)

- ♦ **Précision** = $TP / (TP + FP)$

Exactitude : pourcentage d'exemples que le classificateur a étiqueté comme positifs qui sont réellement positifs

- ♦ **Rappel** = $TP / (TP + FN)$ (ou sensibilité)

Complétude : pourcentage d'exemples réellement positifs que le classificateur a marqué comme positifs ?

- ♦ **F1-mesure** ou **F1-score** = $(2 * Précision * Rappel) / (Précision + Rappel)$

		Classe prédite	
		Oui	Non
Classe réelle	Oui	TP	FN
	Non	FP	TN

Rappel (Sensibilité)


Spécificité

Précision

Évaluation de modèles

Courbe ROC

- ◆ Courbe **ROC** (Receiver Operating Characteristic)
- ◆ Comparaison **visuelle** de modèles de classification
- ◆ Taux de vrais positifs (**sensibilité**) en fonction du taux de faux positifs (**1-spécificité**)
- ◆ **AUC**, aire sous la courbe ROC : mesure de performance



Sélection de modèles

- ◆ **Performances** : accuracy, AUC, ...
- ◆ **Vitesse**
 - ◆ temps pour construire le modèle (apprentissage)
 - ◆ temps d'utilisation du modèle (prédiction/classement)
- ◆ **Robustesse** : gestion du bruit et des valeurs manquantes
- ◆ **Évolutivité**
- ◆ **Interprétabilité des résultats**
- ◆ **Explicabilité**
- ◆ **Contraintes externes** (de l'entreprise, ...)

Gérer les classes déséquilibrées

- ◆ Dans nombreux cas : **classes déséquilibrées** (détection de fraude, d'intrusion, ...)
- ◆ Certaines mesures d'évaluation comme l'*accuracy* ne sont pas adaptées pour les classes déséquilibrées
- ◆ **Modification de la distribution des données d'apprentissage** pour que la classe rare soit bien représentée
 - ◆ **Sous-échantillonner** la classe majoritaire
 - ◆ **Sur-échantillonner** la classe rare
- ◆ L'utilisation d'une **méthode d'aggrégation de modèles** peut aussi être utile

Méthodes d'agrégation de modèles

- ◆ Objectif : amélioration des performances d'un classifieur
- ◆ **Méthode d'ensemble**
 - ◆ Boosting
 - ◆ Entraînement de chaque nouveau modèle de façon à mettre l'accent sur les exemples d'apprentissage que les modèles précédents ont mal classés
 - ◆ Les modèles sont formés en série
 - ◆ Bagging
 - ◆ Entraînement de chaque modèle à l'aide d'un sous-ensemble de l'ensemble d'apprentissage
 - ◆ Les modèles sont formés en parallèle

Méthodes d'agrégation de modèles - Boosting

- ◆ Approche **collaboratrice** ou complémentaire contrairement au Bagging (compétitive)
- ◆ Les classifieurs sont introduits un à la fois et travaillent sur des **sous-ensembles différents**
- ◆ Chaque **nouveau classifieur s'occupe des exemples mal classés par les autres**
- ◆ Les classifieurs sont médiocres (le Boosting n'aurait pas beaucoup d'intérêt sinon)
- ◆ Les classifieurs peuvent être de **types différents** (arbre de décision, réseaux de neurones, ...)

Méthodes d'agrégation de modèles - Bagging

- ♦ Bagging : **Bootstrap AGGregatING**
- ♦ On construit I sous-ensembles contenant m_i objets ($m_i < n$) de l'ensemble des données D (avec remise)
- ♦ Chaque **sous-ensemble** est utilisé pour **entraîner un classifieur**
- ♦ La décision finale est basée sur un **vote**
- ♦ Généralement, les classifieurs sont de la **même forme**
- ♦ **Améliore la performance** des classifieurs en "moyennant" leurs réponses

RandomForest

- ◆ **Arbres de décision** + variante du **Bagging**
- ◆ Construction d'un ensemble d'arbres de décision :
 - ◆ Utilisation d'un **sous-ensemble de données d'apprentissage** en échantillonnant avec remplacement pour chaque arbre
 - ◆ À chaque nœud, utilisation d'une **sélection aléatoire de variables** comme candidats et séparation selon la meilleure variable parmi elles
- ◆ Classement/Prédiction : chaque arbre donne une classe et la plus populaire gagne (**vote à la majorité**)

Pour finir (1/2)

Étapes (classiques) :

- ◆ Chargement et préparation des données
- ◆ Préparation des données pour la modélisation
- ◆ Création et entraînement de modèles (sur "train")
- ◆ Évaluation de modèles (sur "test")
- ◆ Réglage des hyper-paramètres
- ◆ Création d'un pipeline de traitement
- ◆ Persistance du modèle (pour passage en production)

Pour finir (2/2)

- ♦ Il faut toujours se souvenir que :
 - "**Tous les modèles sont faux mais certains sont utiles**", George Box, 1976.
 - "**No free lunch**", David Wolpert et William Macready, 1997.
- ♦ Attention aux **biais** dans les données (cf. annexe)

ANNEXE

Biais dans les données

Compléments sur l'évaluation

Autres méthodes et algorithmes

Biais dans les données

- ◆ Présence de **biais** : possibles **conséquences graves**
- ◆ Admission à l'université, obtention de crédits, détermination de peines selon les risques de récidive (justice), mise en place d'une "police prédictive", ... (→ *Loi sur l'IA de l'Union Européenne* !)
- ◆ *"Les modèles sont des ensembles d'opinions insérés dans un système informatique"*, Cathy O'Neil, Algorithmes, 2018.
- ◆ Types de biais :
 - ◆ **cognitifs** (biais de stéréotype, biais de "corrélations illusoire", ...),
 - ◆ **statistiques** (biais de sélection, biais de variable omise, ...),
 - ◆ **économiques** (phénomène du "search engine manipulation", ...)
- ◆ Données non représentatives, incorporation (involontaire) de stéréotypes, ...
- ◆ Problèmes de discrimination et manque d'équité


Évaluation de modèles

Bootstrap

- ◆ Soit un ensemble d'apprentissage D de n éléments
- ◆ Choisir **K ensembles de n éléments** avec remise à chaque sélection
 - ◆ Il y aura donc presque toujours duplication de certains exemples dans les ensembles créés
- ◆ Évaluer les **performances avec les éléments non sélectionnés pour l'entraînement**
- ◆ Fonctionne bien avec de petits ensembles de données

Régression logistique


- ◆ Utilise la fonction sigmoïde (logistique)
- ◆ $S(x) = 1 / (1 + e^{-x})$



Linear Probability
Model

SVM



- ◆ Support Vector Machines
- ◆ Machines à vecteurs de support ou Séparateurs à vaste marge
- ◆ Utilisation d'une fonction noyau si non linéairement séparable




Support Vectors

Réseaux de neurones

◆ Réseaux de neurones multicouches



Descente de
gradient



Gradient boosting

- ◆ Construction d'une série de modèles
 - ◆ Les modèles peuvent être n'importe quel modèle prédictif qui a une fonction de perte différentiable
 - ◆ Généralement, les arbres de décision sont choisis
- ◆ Boosting : optimisation de la fonction de perte par descente de gradient itérative

Réseaux bayésiens

◆ Exemple

$P(C)$
.001

Cambriolage

Tremblement
DeTerre

$P(T)$
.002

Alarme

C	T	$P(A C, T)$
v	v	.95
v	f	.94
f	v	.29
f	f	.001

JohnAppelle

MarieAppelle

A	$P(M A)$
v	.70
f	.01

$$p(X) = \prod_k p(x_k | \text{Parents}(x_k))$$